

Taller Final: Predicción y Clasificación en la Industria Azucarera

1. Contexto y Objetivos

Este taller tiene como objetivo aplicar los conocimientos adquiridos en el curso de aprendizaje de máquinas I, para desarrollar modelos de regresión y clasificación que permitan predecir dos variables clave del proceso de producción y cosecha de caña de azúcar, como lo son, las toneladas de caña por hectárea (**TCH**) y el porcentaje de sacarosa (**%Sac.Caña**). Los indicadores TCH y %Sac.Caña son fundamentales y de mucho interés dado que, el **TCH** representa la productividad agrícola; valores altos indican un mayor rendimiento del cultivo. Por otro lado, el porcentaje de **Sacarosa** refleja la calidad del cultivo, ya que un mayor contenido de sacarosa se traduce en un mayor potencial para la extracción de azúcar.

Para alcanzar el objetivo, utilizaremos dos conjuntos de datos entregados por un ingenio azucarero. Con el primer conjunto de datos aplicaremos modelos de regresión para predecir el TCH y el %Sac.caña (**HISTORICO_SUERTES.xlsx**). De manera similar, con el segundo conjunto de datos realizaremos una metodología para ajustar modelos de clasificación para ambas variables de interés (**BD_IPSA_1940.xlsx**). Estos datos otorgados por un ingenio de Colombia, cuentan con un extenso conjunto de observaciones históricas que recogen información relevante sobre la producción de caña de azúcar, desde las condiciones agronómicas y el manejo de cultivos hasta los resultados de cosecha.

Las siguientes secciones de este informe se han estructurado en dos partes, uno por caso de modelado, es decir, por casos de regresión y clasificación. En cada sección mencionamos la metodología y los principales resultados obtenidos.

2. Procesamiento y análisis exploratorio de datos

En esta sección mencionamos los pasos de limpieza/transformación de los datos, y los hallazgos del análisis exploratorio de datos (EDA), previos a las etapas de modelado.

2.1. Casos de Regresión - Historico_suertes

En primer lugar, en este conjunto de datos contamos con más de 20.000 observaciones y más de 80 columnas. Cada observación hace referencia a una cosecha de caña de azúcar, realizada en una suerte de una hacienda, en un periodo de tiempo específico. Las columnas, cuentan con información relacionada a cada cosecha, como lo pueden ser las características de la hacienda y el suelo, características del cultivo, maduración del cultivo de caña, irrigación y precipitaciones durante el ciclo, entre otras.


Al realizar una primera exploración de los datos, notamos un gran número de valores faltantes, errores de tipo de formato, columnas con un gran número de niveles, posibles errores de escritura/digitación, variables con potencial de introducir data leakage, entre otros problemas. Debido a lo anterior, para aproximadamente todas las columnas realizamos algún tipo de ajuste o modificación, estos pasos quedaron registrados en el notebook [notebooks_regresion/data_preprocessing.ipynb](#). A continuación, y antes de proceder con el EDA, realizamos un proceso riguroso de imputación de variables claves y un proceso de creación de nuevas variables a partir de las variables ya existentes. En el proceso de imputación, evitamos cometer errores que introduzcan data leakage a los modelos; realizamos imputaciones agrupando por haciendas, zonas geográficas, edades de los cultivos y periodos de cosecha similares. Además, en el proceso de creación de nuevas variables logramos construir variables de interés como:

- Años totales desde la primera siembra hasta cada cosecha (edad_siembra_a_ult_cos)
- Macro-variedad de la caña, donde agrupamos las variedades de caña (variedad_v2)
- Agrupación de productos de maduración, con menos niveles de producto (producto_categoria)
- Booleano de adición de algún fertilizante (algun_fertilizante)
- Litros totales de agua por hectárea, combinando la irrigación con precipitaciones (agua_total_l_ha)
- Variables divididas por el total de hectáreas de la suerte, para hacerlas más comparables.
- TCH de plantación similar, utilizando cosechas antiguas y un modelo de KNN (previous_similar_tch)

Estas transformaciones y manejos del conjunto de datos se pueden consultar en el notebook [notebooks_regresion/FE_regression.ipynb](#) con la respectiva justificación y pasos de aplicación.


Ahora, para el proceso de EDA ([notebooks_regresion/EDA_regression.ipynb](#)), se llevó a cabo dos enfoques con el objetivo de identificar variables relevantes y posibles outliers. Primeramente implementamos un enfoque univariado para conocer la distribución de las variables objetivo y de las potenciales variables predictoras. Seguidamente, realizamos un análisis con enfoque multivariable para conocer la relación entre diferentes variables de interés contra el TCH y el %sac.caña, obteniendo así mayor conocimiento sobre las variables más correlacionadas y con mayor potencial de predicción.

Del análisis univariado obtenemos:




En primer lugar, podemos notar una pronunciada distribución normal para las variables de interés (TCH y %Sac.caña). Además, en las líneas de tiempo podemos observar unos valores altos o bajos muy puntuales, los cuales pueden ser considerados como posibles outliers. Se realizó el mismo análisis para todas las variables numéricas y categóricas del conjunto de datos.

Del análisis multivariado, notamos relaciones interesantes para cada variable objetivo. Por ejemplo:



Observamos que la variedad de la caña presenta una relación con el TCH, en especial las variedades después del año 2000, las cuales presentan en promedio un mayor rendimiento. Notamos que a mayor número de cosechas en el mismo suelo (sin re-sembrar) afecta las toneladas producidas por el cultivo de caña, disminuyendo el TCH cosecha a cosecha. Por último, notamos como algunas variables de precipitaciones y de edad de la última cosecha, son directamente proporcionales al TCH. Con respecto al porcentaje de sacarosa:



En este caso, lo más notable es que las variedades anteriores al año 2000 presentan en promedio un mayor % de Sacarosa, de igual manera, entre más años se tenga entre la primera siembra y el último cultivo, mayor sacarosa se evidencia. Entre algunas variables que presentan una relación inversa con la sacarosa tenemos las precipitaciones o litros de agua total por hectárea, y si el cultivo es orgánico también se observan porcentajes de sacarosa más bajos.

2.2. Casos de Clasificación (BD_IPSA_1940.xlsx)

En este segundo conjunto de datos, denominado **BD_IPSA_1940.xlsx**, se contó con un total de 2,187 observaciones y 21 columnas iniciales, todas ellas completas (sin valores nulos). Varias de estas columnas correspondían a identificadores (como unnamed_0, faz, tal, etc.) o bien tenían un carácter descriptivo muy específico del campo, sin aportar valor predictivo claro para la clasificación. Tras un análisis exploratorio y de correlaciones, se decidió eliminar aquellas variables con correlaciones cercanas a cero o con un enfoque meramente identificativo (por ejemplo, la columna que funciona como índice). De este modo, se seleccionaron únicamente las columnas más relevantes para el modelado de la calidad y la productividad de la caña.

La investigación documental sobre la **caña de azúcar** respalda este proceso de filtrado de columnas. En la literatura, se enfatiza que los factores con mayor impacto sobre la producción de caña (en toneladas por hectárea, TCH) y su calidad (porcentaje de sacarosa en la caña, %Sac.Caña) suelen ser la edad de cultivo, las prácticas de fertilización, la variedad de caña sembrada, la humedad disponible (lluvias o riego) y la sanidad del cultivo (presencia de plagas como Diatraea). Asimismo, estudios sobre el sector agroindustrial azucarero en Colombia describen un **periodo vegetativo de 13 a 15 meses**, con producciones promedio de **120 toneladas por hectárea** y un rendimiento de sacarosa cercano a **11.6%**, valores que varían según factores climáticos, agronómicos y genéticos. Esta información empírica sirve como referencia para identificar qué columnas realmente contribuyen a explicar la variabilidad de TCH y %Sac.Caña.

Una vez seleccionadas las columnas potencialmente predictivas, se procedió al análisis exploratorio de datos (EDA). Se verificaron sus distribuciones (mediante histogramas y boxplots), las correlaciones de pares de variables (en especial TCH vs. %Sac.Caña), y se observó, por ejemplo, la moderada relación entre la edad del cultivo y las semanas de maduración (semsmad), así como la correlación negativa entre TCH y sacarosa. Estas constataciones coinciden con las descripciones habituales del *trade-off* entre rendimiento y calidad: a medida que la caña produce más biomasa (más TCH), suele concentrar menos porcentaje de azúcares, y viceversa.

Transformación de Variables: Dado que el objetivo es clasificar la calidad y la productividad de la caña, se transformaron las variables continuas TCH y %Sac.Caña en tres categorías: bajo, medio y alto. Esta conversión se realizó mediante la técnica de terciles, que divide la distribución en tres partes aproximadamente iguales. En particular:

- **TCH:** Se consideraron los valores por debajo del primer tercil como “bajo”, entre el primer y el segundo tercil como “medio” y por encima del segundo tercil como “alto”. Esta decisión se basa tanto en la distribución del propio conjunto de datos como en los rangos reportados por la industria colombiana (de 40 a más de 180 toneladas/ha, con un promedio cercano a 120).
- **%Sac.Caña:** Se aplicó el mismo criterio de terciles para distinguir cañas con bajo, medio y alto contenido de sacarosa. Tal como se describe en la literatura, en Colombia el promedio puede rondar entre 11% y 12%, pero hay parcelas donde el contenido es mayor y puede llegar por encima de 13.5%, mientras que en condiciones menos favorables se reportan valores sensiblemente menores.

Para más información y detalles del proceso de transformación y EDA, revisar [notebooks_clasificacion/clasification_eda_model.ipynb](#).

3. Desarrollo y ajuste de modelos

3.1 Casos de Regresión (TCH y Porcentaje de Sacarosa en Caña)

Metodología:

- Se usó **Ridge, Lasso y Polynomial features**. Estas técnicas fueron elegidas debido a su capacidad para controlar la multicolinealidad, sobreajuste y selección de variables significativas.
- Se realizó codificación one-hot de variables categóricas. Las variables numéricas fueron escaladas con **StandardScaler** para asegurar una correcta penalización en la regularización. Se **eliminaron columnas con más del 60% de valores faltantes**. Se aplicó imputación por media en el resto de los valores faltantes.
- Para ambos modelos, Ridge y Lasso, se empleó **validación cruzada de 5 particiones (5-fold)** junto con búsqueda de hiperparámetros mediante **GridSearchCV**, lo que permitió obtener estimaciones más robustas del rendimiento del modelo y reducir el riesgo de sobreajuste. Se ajustaron modelos tanto con como sin transformación polinomial de las variables predictoras. En los casos con transformación, esta se aplicó mediante **PolynomialFeatures(degree=2)**, permitiendo al modelo capturar relaciones no lineales e interacciones entre variables, mientras que la validación cruzada garantizó que dichas mejoras en la complejidad del modelo se reflejarán en un mejor desempeño generalizado.
- Se utilizaron tres métricas clave para evaluar la calidad del ajuste, **MAE, RMSE y R²**. Además del desempeño numérico, se realizó un diagnóstico visual de residuos para evaluar los supuestos del modelo lineal: **linealidad, homocedasticidad y normalidad de los errores**.
- Se llevó a cabo un análisis y verificación de los **coeficientes de las variables predictoras** con el objetivo de identificar aquellas que más contribuyen a la predicción, así como las que tienen un impacto mínimo y pueden considerarse poco útiles para el modelo.
- Finalmente, se compararon los modelos Ridge y Lasso (con y sin polinomios) en ambas variables objetivo.

3.2 Casos de Clasificación

Desarrollo de los Modelos: Base vs. Optimizado

En primera instancia, se construyó un modelo base para cada variable objetivo (Sacarosa y TCH) mediante dos algoritmos: Regresión Logística (con parámetros por defecto) y K-Nearest Neighbors (k=5, weights='uniform'). Estos se encapsularon en pipelines que incluían un escalado de las variables numéricas con StandardScaler. Luego, se utilizó una validación cruzada estratificada (cinco particiones) y se evaluaron las métricas de exactitud (accuracy), precisión, recall y F1-score.

Los resultados iniciales mostraron un buen desempeño en las clases intermedias, pero presentaron dificultades al clasificar los valores bajos y altos. Con el fin de mejorar, se aplicó una optimización de hiperparámetros mediante GridSearchCV y BayesSearchCV. En Regresión Logística, se ajustó el parámetro de regularización C, mientras que en KNN se exploró la variación de k y la forma de ponderar las distancias (uniform o distance). Tras este proceso, KNN evidenció un aumento más significativo en la exactitud, sobre todo al usar ponderación por distancia y un número óptimo de vecinos, mientras que la Regresión Logística solo mostró mejoras leves. Estas observaciones sugieren que el comportamiento complejo de las clases, relacionado con la variabilidad agronómica, se adapta mejor a un método no paramétrico como KNN.

4. Resultados e interpretaciones

4.1 Casos de Regresión

Tabla Comparativa Resultados Modelos Aplicados para predicción de TCH y Pct_Sac_Caña

Como se puede observar a continuación, la combinación de ridge/lasso + características polinómicas representó una mejora notable en el ajuste, lo que sugiere la existencia de relaciones no lineales en el fenómeno productivo.

Modelo	MAE (TCH)	RMSE (TCH)	R² (TCH)	MAE (%Sac.Caña)	RMSE (%Sac.Caña)	R² (%Sac.Caña)
Ridge + Poly	19.93	26.17	0.354	0.6926	0.9085	0.3602
Lasso + Poly	20.05	26.26	0.350	0.6932	0.9081	0.3608
Lasso	20.99	27.34	0.295	0.7322	0.9481	0.3032
Ridge	20.98	27.34	0.295	0.7318	0.9481	0.3032

De acuerdo con el análisis gráfico para residuos y distribuciones, ambos modelos lineales (Ridge y Lasso, tanto para TCH como para Sac) muestran **residuos centrados en cero**, sin patrón visible ni forma de abanico. Esto indica que la **relación entre predicciones y errores es lineal y no hay heterocedasticidad** fuerte. Los residuos siguen una forma de campana simétrica bien centrada en cero. No se observan colas pesadas ni asimetrías importantes. De acuerdo con el QQ Plot para ambos modelos, los residuos se alinean bien con la línea teórica de distribución normal, con pequeñas desviaciones en las colas. Esto sugiere que **los errores del modelo son aproximadamente normales**, lo cual es adecuado para la veracidad en las conclusiones de una regresión lineal. Para mayor explicación, resultados y análisis de los coeficientes, revisar [notebooks_regresion/modelling_regression.ipynb](#)

4.2 Casos de Clasificación

La siguiente tabla presenta las métricas principales (Accuracy, Precisión Macro, Recall Macro y F1-score Macro) tanto en su versión base como optimizada para los dos algoritmos (Regresión Logística y KNN) y los dos objetivos (Sacarosa y TCH).

Objetivo	Modelo	Versión	Accuracy	Precisión (macro)	Recall (macro)	F1 (macro)
Sacarosa	Reg. Logística	Base	0,5457	0,5125	0,4627	0,4606
Sacarosa	KNN (k=5, uniform)	Base	0,5409	0,5073	0,4999	0,4983
Sacarosa	Reg. Logística (C=0.1)	GridSearch	0,5474	0,5223	0,4551	0,4462
Sacarosa	KNN (k=26, distance)	Optimizada	0,5842	0,5754	0,5057	0,5099
TCH	Reg. Logística	Base	0,6237	0,3464	0,3444	0,2842

TCH	KNN (k=5, uniform)	Base	0,5609	0,4290	0,4048	0,4086
TCH	Reg. Logística (C=0.1)	Optimizada	0,6248	0,3312	0,3387	0,2692
TCH	KNN (k=22, distance)	Optimizada	0,6394	0,6009	0,3850	0,3630

Los resultados muestran que, en general, los modelos base (Regresión Logística y KNN) presentan dificultades notables para clasificar correctamente las clases “bajo” y “alto”, reflejando la complejidad de los datos y la menor frecuencia de esas categorías. Sin embargo, al aplicar optimizaciones con GridSearch y BayesSearch, se evidencian mejoras significativas, sobre todo en KNN al ajustar adecuadamente el número de vecinos y usar ponderación por distancia. Por su parte, la Regresión Logística exhibe incrementos más modestos, indicando que la relación lineal asumida no capta por completo las variaciones propias de estas clases. De manera global, las clases intermedias (o “normal”) resultan más sencillas de predecir, mientras que las clases extremas siguen siendo un reto y podrían requerir técnicas de balance de clases o datos adicionales para mejorar su detección. Estos hallazgos resaltan la importancia de la selección de hiperparámetros y del uso de métodos más flexibles (como KNN) en contextos con alta variabilidad agronómica y distribución desequilibrada de clases. Para mayor explicación, resultados y análisis, revisar [notebooks clasificacion/clasificacion_edamodel.ipynb](#).

5. Conclusiones y propuestas

5.1 Modelo de Regresión

En el caso de la variable TCH, el modelo que ofreció mejor desempeño fue **Ridge con términos polinomiales**, alcanzando un R^2 de **0.354**, mientras que para el porcentaje de sacarosa en caña, el modelo más preciso resultó ser **Lasso con polinomios**, con un R^2 de **0.3608**. En ambas predicciones, se identificaron como factores clave la **edad de cosecha**, la **zona geográfica** y la **variedad sembrada**, evidenciando su peso determinante tanto en la productividad como en la calidad del cultivo.

Dado el nivel de ruido inherente y la presencia de valores faltantes, se recomienda considerar técnicas más robustas como **Random Forest**, **XGBoost** o **LightGBM**. Adicionalmente, la creación de nuevas variables o la selección de cosechas con información completa y veraz, podría orientar la obtención de mejores resultados. Por último, aunque los valores de R^2 obtenidos pueden parecer modestos desde una perspectiva estadística tradicional, en un contexto agrícola con datos reales y alta variabilidad, se consideran **aceptables y útiles**. Es recomendable evaluar estos resultados frente a referencias internas o estudios similares para tener un mejor marco de interpretación.

5.2 Modelo de clasificación

La estrategia de partir de modelos base y luego refinar sus hiperparámetros mediante métodos sistemáticos de búsqueda (GridSearch y BayesSearch) demuestra que, aunque la Regresión Logística puede ser útil y relativamente estable, KNN responde de manera más notable a la optimización, especialmente al abordar la complejidad de las clases extremas de rendimiento y calidad en la caña. Los resultados confirman la alta variabilidad agronómica y la necesidad de ajustar cuidadosamente los parámetros –sobre todo en algoritmos no paramétricos– para mejorar la detección de categorías minoritarias o extremas. Pese a las dificultades persistentes en los casos “bajo” y “alto”, estas mejoras reflejan el potencial de una aproximación iterativa y enfocada en métricas detalladas para la toma de decisiones agronómicas más informadas.

Los resultados tanto en regresión como en clasificación muestran la complejidad del cultivo de caña y la relevancia de afinar los modelos. En el caso de la regresión, Ridge y Lasso con polinomios lograron R^2 alrededor de 0.35, lo cual, aunque aceptable, sugiere la conveniencia de algoritmos más robustos (como Random Forest o XGBoost). Por otro lado, en la clasificación, los modelos base evidenciaron dificultades con las clases extremas, pero la optimización de hiperparámetros (en especial para KNN) mejoró significativamente la precisión. En conjunto, estos hallazgos subrayan que la alta variabilidad agronómica demanda métodos ajustados y un proceso iterativo de modelado para respaldar decisiones más confiables en la agroindustria azucarera.

6. Referencias

- Sector Agroindustrial de la Caña. (2023). Informe anual 2023-2024. Recuperado de: <https://www.asocana.org/documentos/2562024-B8F8FBCE-00FF00,000A000,878787,C3C3C3,0F0F0F,B4B4B4,FF00FF,FFFFFF,2D2D2D,A3C4B5.pdf>
- Secretaría de Agricultura y Desarrollo Rural. (2019, 20 de agosto). *Etapas del cultivo de caña*. Gobierno de México. Recuperado de <https://www.gob.mx/agricultura/articulos/etapas-del-cultivo-de-cana>
- Ingenio Providencia. (2016). *Procesos de Ingenio Providencia*. Recuperado de https://www.providenciaco.com/wp-content/uploads/2016/05/Procesos_de_Ingenio_Providencia.pdf
- EOS Data Analytics. (2023). *Cultivo de caña de azúcar: de la siembra a la cosecha*. Recuperado de <https://eos.com/es/blog/cultivo-de-cana-azucar/>